Aprendizaje automático en la detección de enfermedades caninas: Una revisión sistemática

Quispe Tufino, Alejandro

***Abstract*-- La detección temprana de enfermedades caninas enfrenta importantes desafíos debido a la variabilidad clínica entre razas, la complejidad diagnóstica y la creciente disponibilidad de datos heterogéneos. En este contexto, el Aprendizaje Automático (Machine Learning, ML) se ha convertido en una herramienta clave para optimizar, automatizar y mejorar la precisión diagnóstica en medicina veterinaria. El objetivo de esta revisión sistemática fue analizar la producción científica reciente (2021–2025) relacionada con la aplicación de ML en la detección de enfermedades caninas, identificando tendencias, enfoques metodológicos, tipos de datos, así como las áreas clínicas y modelos más empleados. Para ello, se realizó una búsqueda en Scopus, IEEE Xplore, EBSCO Host y PubMed, utilizando operadores booleanos y criterios PRISMA, obteniéndose inicialmente 486 artículos y seleccionándose finalmente 94 estudios que cumplían los criterios de inclusión.**

La investigación evidencia que el ML se utiliza principalmente en oncología, cardiología y neurología, con énfasis en imágenes médicas y modelos CNN. Las tareas más comunes son detección y clasificación, consolidando al ML como apoyo clave en el diagnóstico canino temprano.

Keywords: machine learning veterinario, enfermedades caninas, imágenes médicas, diagnóstico automatizado

I. Introducción

La complejidad del diagnóstico veterinario debido al gran volumen de datos clínicos y la variabilidad entre razas y presentaciones hace que la detección temprana de enfermedades caninas sea un reto. En respuesta, el Machine Learnin está transformando este proceso al ofrecer diagnósticos más precisos, objetivos y aplicables en múltiples áreas clínicas.

Un área pionera ha sido el diagnóstico cardiológico. El trabajo sobre enfermedad mixomatosa de la válvula mitral (MMVD) demostró que modelos como CNN6, PaSST y ResNet38 son capaces de interpretar fonocardiogramas digitales con notable precisión, permitiendo estimaciones objetivas de severidad en una patología altamente prevalente cuya confirmación depende de ecocardiografías especializadas, costosas y de disponibilidad limitada [1]. De forma complementaria, otro estudio evaluó un algoritmo basado en redes recurrentes para la detección y gradación automática de soplos cardiacos, logrando sensibilidades cercanas al 88% e incluso diferenciando estadios preclínicos B1 y B2 con un AUC de 0.861, destacando el papel del ML como cribado accesible en consultas primarias [27]. Asimismo, enfoques basados en radiografías torácicas y transformers regresivos demostraron capacidad para predecir cardiomegalia con precisión de última generación, representando un puente entre métricas clínicas tradicionales como el VHS y modelos matemáticos avanzados [24]. Otro estudio utilizó CNNs para clasificar la severidad de la MMVD desde radiografías, obteniendo AUC de hasta 0.90 en la categorización por puntuación MINE [29], mientras que investigaciones más recientes lograron automatizar el cálculo del vertebral heart score con un desempeño comparable al de cardiólogos certificados [46].

Más allá del sistema cardiovascular, otras especialidades también han adoptado estas tecnologías. En dermatología y otología, un modelo YOLOv5 fue entrenado para detectar otitis externa, masas y conductos sanos en imágenes otoscópicas, logrando precisiones elevadas y demostrando la importancia de datasets libres de duplicados para evitar sobreestimación del rendimiento [8]. La dermatología también se ha beneficiado mediante CNNs secuenciales capaces de clasificar lesiones cutáneas (bumps, hot spots, alopecia, rash, sores) con un rendimiento del 84.38%, mostrando el enorme potencial del análisis automatizado de imágenes clínicas [12].

En el terreno de la oncología, el avance es aún más notable. La aplicación de ML en plataformas de inmunocitoquímica virtual permitió analizar masivamente millones de células, segmentarlas y clasificar fenotipos inmunopositivos con sensibilidades superiores al 98%, reduciendo tiempos de diagnóstico y costos asociados a técnicas de laboratorio convencionales [3]. La integración de TK1, cCRP y edad mediante modelos GBM generó el índice Alertix-CRI, alcanzando AUC de 0.98 para la detección precoz de tumores, demostrando la utilidad clínica de biomarcadores séricos potenciados por ML [19]. En paralelo, REIMS combinada con quimiometría permitió distinguir tumores mamarios benignos y malignos con más del 97% de exactitud [20]. Otros estudios han explorado aproximaciones epigenéticas, logrando diferenciar tumores mediante patrones de metilación CpG en células mononucleares periféricas a través de ML, con alta fiabilidad diagnóstica [47], mientras que propuestas integradas basadas en cfDNA y NGS reportaron sensibilidades superiores al 70% para siete tipos de cáncer frecuentes en perros [34]. Asimismo, un biosensor electroquímico reforzado con nanopartículas y combinado con algoritmos ML logró identificar tumores mamarios mediante CA 15-3 y MUC-1 con exactitudes de hasta 98%, demostrando el poder de combinar nanotecnología y ML en diagnósticos no invasivos [30]. Finalmente, en oncología dermatopatológica, un sistema automático capaz de segmentar y clasificar siete tumores cutáneos alcanzó 95% de exactitud, rendimiento comparable a patólogos expertos [48].

En neurología y enfermedades musculoesqueléticas, los avances incluyen modelos destinados a detectar hernia de disco

intervertebral (IVDH) mediante técnicas de dos etapas superiores a YOLOX, logrando AP de 75% en MRI caninas [23]. Otro estudio desarrolló un sistema capaz de identificar automáticamente espacios intervertebrales estrechados, un marcador clave en enfermedad discal, con sensibilidad de 81.5% y especificidad de 95.6% [39]. A nivel óseo, U-Net con módulos de atención permitió detectar espondilosis deformans con concordancia casi perfecta con veterinarios ($\kappa = 0.839$) [37]. Igualmente, en cadera, la detección de displasia de cadera usando CNNs como VGG16 alcanzó precisiones superiores al 98%, ofreciendo soluciones robustas para una de las patologías ortopédicas más comunes en razas grandes [38].

En oftalmología, el ML se ha aplicado tanto para la clasificación de cataratas mediante ultrasonido ocular, con modelos como DenseNet161 logrando 92% de exactitud [13], como para la segmentación de síntomas oculares utilizando pipelines avanzados de U-Net combinados con GPT-4o, alcanzando hasta 97% de precisión en máscaras de síntomas y demostrando que la integración multimodal imagen-texto podría definir la próxima generación de herramientas diagnósticas inteligentes [22]. Complementariamente, modelos SVM han demostrado utilidad para gradar cataratas caninas incluso capturadas desde cámaras móviles, abriendo camino a aplicaciones móviles de bajo costo con precisiones superiores al 81% [17]. Otro sistema U-Net aplicado al diagnóstico de enfermedades oculares mostró IoU superiores al 80%, consolidando la relevancia de la segmentación profunda en esta especialidad [28].

Las patologías respiratorias y otorrinolaringológicas también han sido beneficiadas. Investigaciones sobre tos canina y enfermedades bronquiales demostraron que CNNs superan a MLP y RNN en la clasificación de patrones acústicos, alcanzando los mejores valores de F1 y AUC dentro de los modelos probados [5]. Asimismo, la identificación automática de colapso traqueal mediante YOLO v3/v4/v4-tiny mostró rendimientos excepcionales, con sensibilidades del 98.3% y especificidades del 99.2% [26]. En nariz, redes entrenadas para diferenciar rinitis fúngica, neoplasias y anatomía normal alcanzaron precisiones de 99% al analizar pilas completas de cortes TC, demostrando el impacto del análisis volumétrico [11], mientras que modelos para clasificar estenosis nasal en bulldogs mediante imágenes de narinas lograron un F-score comparable al de expertos [2]. De forma similar, estudios sobre detección de leishmaniasis mediante sensores de VOC integrados con ML mostraron tiempos de diagnóstico menores a 15 minutos, reforzando el valor de combinar biosensores con algoritmos inteligentes [4].

En el campo gastrointestinal y parasitológico, tecnologías como Vetscan Imagyst aplicadas a la detección de Giardia duodenalis demostraron sensibilidades del 88.4% y especificidades superiores al 98%, con alta repetibilidad y facilidad de uso incluso por personal no entrenado [21]. Igualmente, modelos XGBoost aplicados a datos clínicos han alcanzado sensibilidades del 94.3% para diagnosticar shunts portosistémicos, una condición difícil de confirmar sin estudios avanzados, permitiendo usar ML como herramienta de cribado previo a imágenes de alta complejidad [42].

La medicina renal también ha visto importantes desarrollos. Un sistema basado en YOLO y CNN logró clasificar estadiosavanzados de enfermedad renal crónica (CKD) con exactitud del 85%, superando incluso a radiólogos especialistas en escenarios IRIS ≥3, demostrando la capacidad del ML para aportar objetividad y reducir la variabilidad interobservador [36]. Por otro lado, arquitecturas híbridas como PFSH-Net han mostrado mejoras sustanciales en la detección de cálculos renales en TC veterinaria, resolviendo problemas de variabilidad anatómica y detectando lesiones pequeñas con métricas superiores a métodos previos [16].

En salud oral, el ML ha potenciado la detección de periodontitis mediante perfiles microbianos analizados por qPCR, logrando correlaciones elevadas con secuenciación de alto rendimiento y precisiones tempranas de hasta 85% de sensibilidad en modelos diagnósticos para biomarcadores específicos [45].

Finalmente, investigaciones más amplias enfocadas en sistemas inteligentes, modelos neuro-difusos y pipelines multimodales demuestran que ML no solo se aplica a diagnósticos de imagen o biomarcadores, sino también a sistemas de predicción basados en síntomas, como es el caso de modelos neuro-fuzzy que lograron hasta 98% de exactitud incluso con datos ruidosos [25], o modelos de optimización textural (MDIPP + CTNN) que mejoran el rendimiento en la predicción de enfermedades en sistemas de aprendizaje de texturas a gran escala [31]. Otras líneas innovadoras incluyen el uso de ML en mapeo cardíaco T1 sin contraste mediante clustering y redes profundas para mejorar la visualización de infartos crónicos [32], así como herramientas para evaluar degeneración discal adaptadas desde modelos humanos con sensibilidades superiores al 83% [33].

El objetivo de esta revisión fue, por tanto, analizar artículos científicos que destacan el uso del Machine Learning en la detección de enfermedades caninas, con el fin de identificar enfoques actuales, tendencias y perspectivas en el diagnóstico veterinario.

II. METODOLOGÍA

1. Tipo de estudio

El presente articulo fue desarrollado mediante la metodología PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), con el objetivo de realizar una revisión sistemática de la literatura. Esta metodología permitirá identificar, seleccionar, evaluar y sintetizar de manera rigurosa y transparente los estudios relevantes sobre el tema de interés, asegurando la reproducibilidad y la calidad de los hallazgos.

2. Preguntas de investigación

RQ1 ¿Qué países presentan la mayor producción científica, en los últimos cinco años, relacionada con la aplicación del Aprendizaje Automático en la detección de enfermedades caninas?

RQ2 ¿Qué modelos de Aprendizaje Automático son los más utilizados en la detección de enfermedades caninas?

RQ3 ¿Qué áreas clínicas de la medicina canina han sido las más abordadas mediante técnicas de Aprendizaje Automático?

RQ4 ¿Qué tipo de datos son los más empleados en la aplicación de aprendizaje automático a la detección de enfermedades caninas?
RQ5 ¿Qué tipo de tareas son las más empleadas en los modelos de Aprendizaje Automático para la detección de enfermedades caninas?

3. Estrategias de búsqueda

Para dar respuesta a las preguntas de investigación, se realizó una recopilación sistemática de artículos en las principales bases de datos científicas: Scopus, IEEE Xplore, EBSCO Host y PubMed. Esta estrategia permitió la recolección inicial de 486 artículos (Figura 1).

La búsqueda se realizó utilizando una combinación de palabras clave y operadores booleanos para asegurar una cobertura amplia del tema. Los términos considerados fueron: *("machine learning" OR "artificial intelligence" OR "deep learning" OR "neural network") AND ("dog" OR "canine") AND ("disease" OR "illness" OR "health problem" OR "ailment") AND ("identification" OR "detection" OR "classification" OR "prediction")*

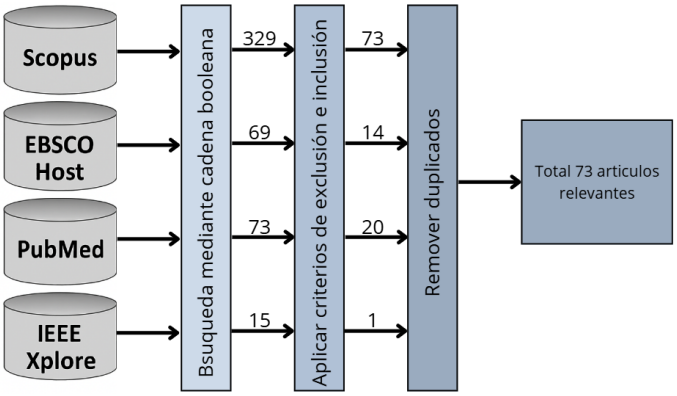


Figura 1. Inclusión de artículos según fuentes.

3.1. Criterios de exclusión e inclusión

La siguiente tabla muestra los criterios de inclusión y exclusión (table 1)

		Criterio
Inclusión	I01	Artículos publicados desde 2021 hasta la fecha.
	I02	Artículos enfocados exclusivamente en perros.
	I03	Artículos que apliquen *machine learning*
	I04	Artículos que tengan como objetivo que detección de una enfermedad.
Exclusión	E01	Artículos publicados antes de 2021
	E02	Artículos en humanos, u otras especies animales.
	E03	Artículos que no apliquen *machine learning*.
	E04	Artículos no enfocados en la detección.

Tabla1. Criterios de inclusión y exclusión

III. RESULTADOS

En total se identificaron 486 artículos. Tras el cribado inicial y la eliminación de 410 por no ajustarse a los criterios metodológicos y duplicación. Finalmente, 94 estudios fueron incluidos en la revision. La Figura 2 muestra el proceso realizado siguiendo el método PRISMA.

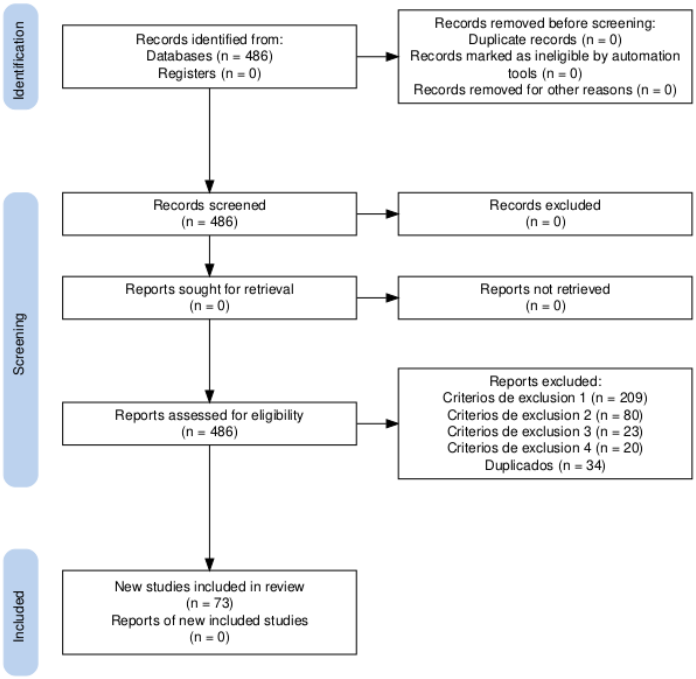


Figura 2. Diagrama de la metodología PRISMA.

La figura 3 muestra la cantidad de artículos por base de datos.

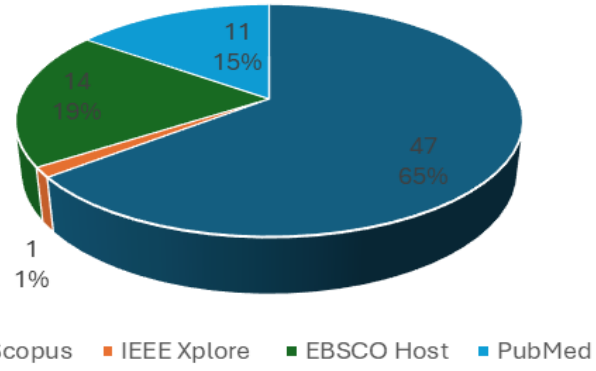


Figura 3. Artículos por base de datos.

La figura 4 muestra la cantidad de artículos publicados por año

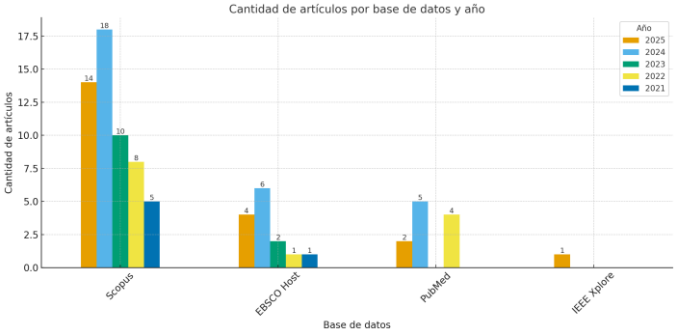


Figura 4. Artículos por año y base de datos.

En la investigación, el análisis bibliométrico se ha convertido en una herramienta clave para identificar tendencias, evaluar impacto científico y mapear redes de colaboración, permitiendo a los investigadores comprender mejor la evolución de un campo y visualizar patrones mediante técnicas como co-ocurrencia, co-citación y análisis de instituciones empleando software especializado como VOSviewer y CiteSpace[74]
En la figura 5 se aprecia el mapa creado para la investigación actual.

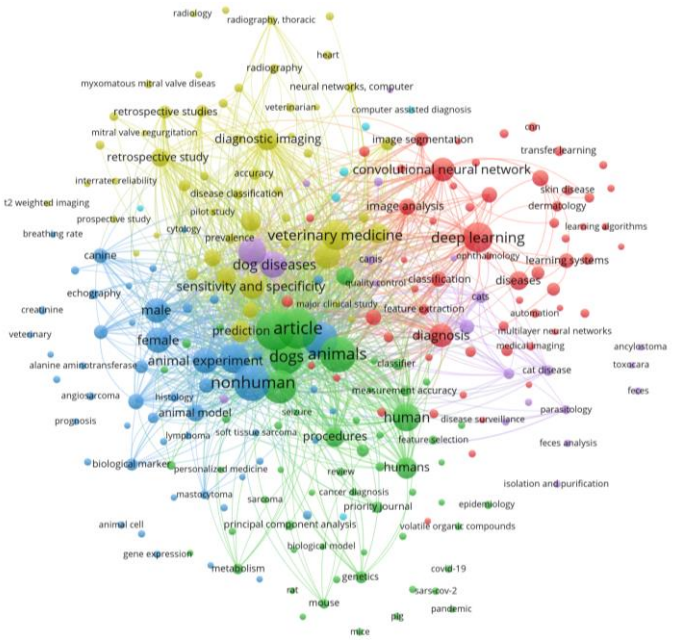


Figura 5. Visualización de la red de documentos disponibles en la base de datos Scopus basada en análisis bibliométrico.

El Cluster 1(red): agrupa términos directamente relacionados con el uso de Machine Learning, redes neuronales y técnicas computacionales aplicadas al diagnóstico, clasificación y análisis de enfermedades. Este cluster muestra que la línea temática dominante se centra en modelos de aprendizaje automático, procesamiento de imágenes médicas, y tecnologías de diagnóstico asistido por computadora.

El Cluster 2(verde): agrupa conceptos que indican un fuerte enfoque en modelos animales, biomarcadores, biología molecular, epidemiología, y validación experimental. Este cluster muestra que esta parte del mapa bibliométrico está relacionada con estudios preclínicos, biomédicos y de caracterización biológica más que con metodologías puramente computacionales.

El Cluster 3(azul): agrupa conceptos relacionados con diagnóstico clínico, biomarcadores, fisiología, estudios comparativos y validación médica en animales, con un fuerte énfasis en perros (caninos) y en la práctica veterinaria. Este cluster refleja la dimensión clínico-biológica aplicada, donde se combinan análisis moleculares, técnicas diagnósticas y resultados clínicos.

La figura 6 muestra las indexed keywords y author keywords basado en los documentos disponibles en la base de datos de scopus.



Figura 6. Visualización superpuesta de los documentos disponibles en la base de datos Scopus: nube de palabras.

La Figura 7 muestra el treemap con la distribución porcentual de los términos más recurrentes obtenidos de la base de datos Scopus a partir del análisis bibliométrico.

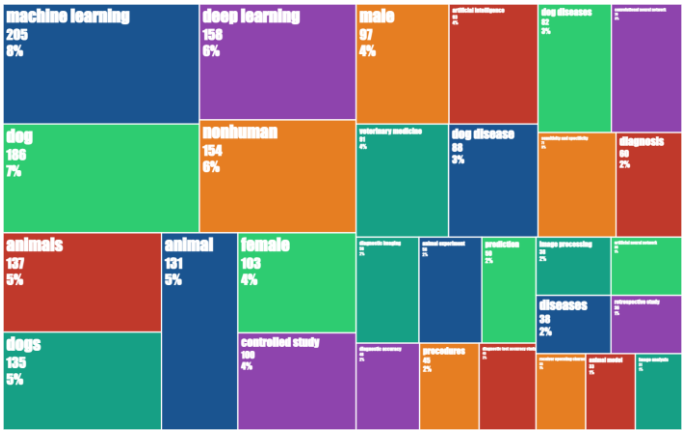


Figura 7. Visualización de los documentos basado en análisis bibliométrico.

La figura 8 muestra la distribución de artículos por área clínica y país
La figura 9 muestra la distribución de artículos por tipo de tarea y continente.
La tabla 2 muestra los países con la cantidad de artículos por cuartil.

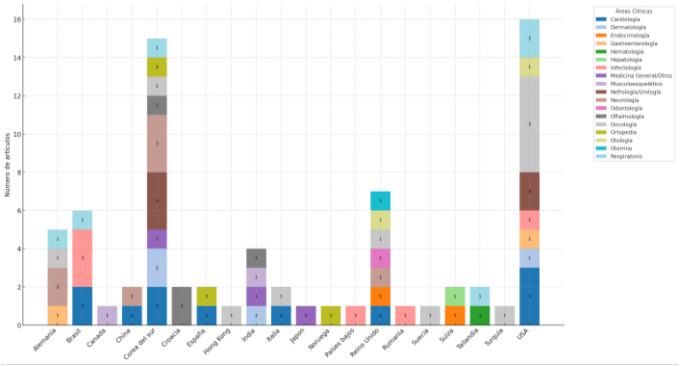


Figura 8. Distribución de artículos por área clínica y país.

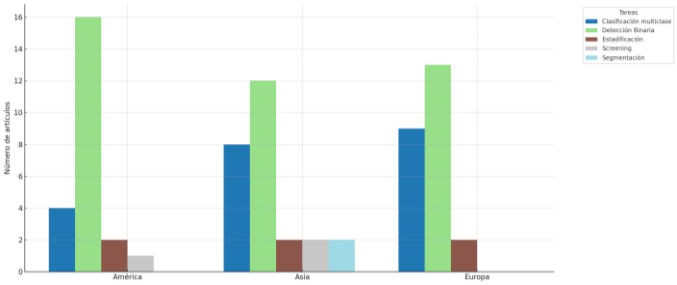


Figura 9. Distribución de artículos por tipo de tarea y continente.

País	Q1	Q2	Q3	Q4
Alemania	4	1	0	0
Brasil	3	1	0	2
Canadá	0	1	0	0
China	2	0	0	0
Corea del sur	12	2	1	0
Croacia	2	0	0	0
España	2	0	0	0
Hong Kong	0	0	0	1
India	1	2	1	0
Italia	1	1	0	0
Japón	1	0	0	0
Noruega	1	0	0	0
Países bajos	1	0	0	0
Reino Unido	7	0	0	0
Rumania	1	0	0	0
Suecia	1	0	0	0
Suiza	1	1	0	0
Tailandia	2	0	0	0
Turquía	0	1	0	0
USA	12	4	0	0

Tabla 2. Cantidad de artículos de país según cuartil.

IV. DISCUSIÓN

Esta revisión sistemática tiene como objetivo proporcionar respuestas a las preguntas planteadas.

1. *RQ1. ¿Qué países presentan la mayor producción científica, en los últimos cinco años, relacionada con la aplicación del aprendizaje automático en la detección de enfermedades caninas?*

La figura 10 muestra la cantidad de artículos según país, en los más destacados tenemos a Estados unidos, Corea del Sur Reino unido, Brasil Alemania.

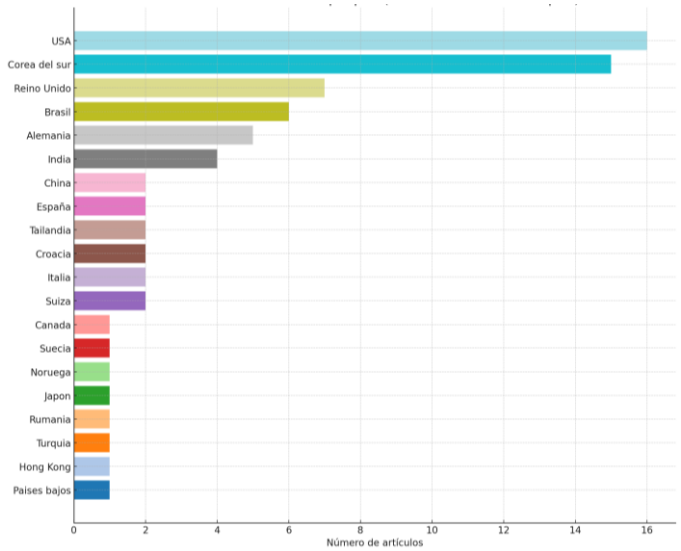


Figura 10. Distribución de artículos por país.

La figura 11 muestra la distribución de artículos por número de cuartil y país . Se evidencia como Estados Unidos predomina no solo en la cantidad de artículos, sino también en el prestigio, el segundo es Corea del sur, y como tercer lugar a Reino unido.

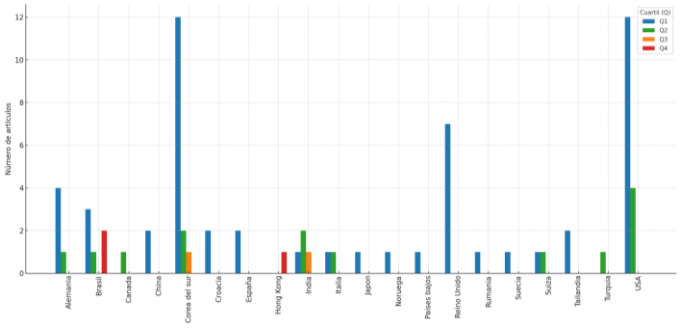


Figura 11. Distribución de artículos por cuartil y país.

2. *RQ2. ¿Qué modelos de aprendizaje automático son los más utilizados en la detección de enfermedades caninas?*

Dada la cantidad de modelos vistos, se han agrupado convenientemente en tipos. Como se aprecia en la tabla 3

Tipo de modelo	Modelos Incluidos
CNN / U-Net	CNN, U-Net, ResNet (18/34/38/50/50V2/101), VGG16, DenseNet (161/201), MobileNet (V2/V3), EfficientNet (B3/B5), Inception (V3/GoogLeNet), AlexNet, HRNet, ResUNet++, ResAttNet, Attention U-Net, 1D-CNN, LiDSCUNet++, UNet++, Sequential CNN, Heart-CNN, CTNN
Detección de objetos	YOLO (v3/v4/v5/v8/X/Tiny), R-CNN, RetinaNet, StarDist
Transformers / Vision Transformers	Vision Transformers (ViT), SwinV2, MaxViT, PaSST, GPT-4o, UNet Transformers, MLMs
Otras redes profundas (RNN/MLP/ANN)	RNN, MLP, ANN, DNN, SOM, Neuro-fuzzy (MNFL/FHAL/PFCM-R), PFSH-Net, Counting model
ML clásico (individual)	SVM, Random Forest, GBM, XGBoost, Decision Tree, KNN, Naive Bayes, Logistic Regression, LDA, LASSO, Extra Trees, KSVM
Ensemble ML clásico	Ensemble combinations (KNN + Decision Tree + Majority Voting, LR + LDA + RF + KSVM + KNN, SVM + RF + GBM + Logistic + KNN, Bagging + RF + Extra Trees)
AutoML / Plataformas comerciales	AutoML, NGS, Chemometrics, Vetscan Imagyst, Vetology AI

Tabla 3. Tipos de modelos

En la figura 12 muestra la cantidad de tipos de modelos usados. Los tipos de modelos más usados son las CNN/U-net y las ML clásico(individual).

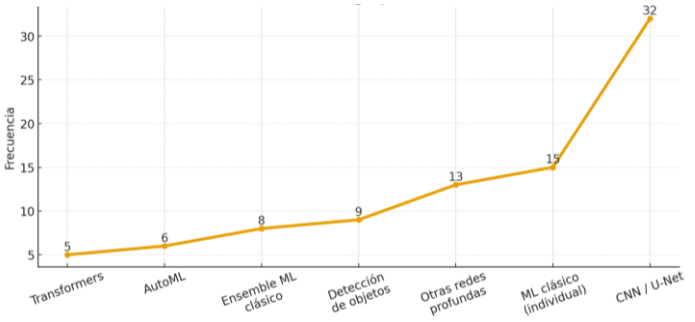


Figura 12. Cantidad de tipo de modelos usados.

De acuerdo con la tabla 4, se puede ver el tipo de modelo según artículos, cabe recalcar que en algunos artículos se han usado más un tipo de modelo.

Tipo de modelo	Frecuencia	#de articulo
CNN / U-Net (visión por DL)	32	1, 2, 5, 6, 10, 11, 12, 13, 18, 22, 28, 29, 31, 36, 37, 38, 39, 41, 46, 48, 49, 50, 52, 53, 54, 55, 58, 59, 61, 67, 68, 69
Detección de objetos	9	3, 8, 10, 18, 23, 26, 36, 53, 72
Transformers / Vision Transformers	5	1, 2, 24, 58, 62
Otras redes profundas	13	4, 5, 7, 9, 14, 16, 25, 27, 30, 32, 33, 60, 73
ML clásico (individual)	15	3, 9, 14, 17, 19, 30, 34, 35, 40, 42, 43, 51, 56, 63, 70
Ensemble ML clásico	8	44, 45, 47, 57, 64, 65, 66, 71
AutoML / Plataformas comerciales	6	15, 20, 21, 34, 50, 59

Tabla 4. Clasificación de artículos según tipo de modelo

3. RQ3. ¿Qué áreas clínicas de la medicina canina han sido las más abordadas mediante técnicas de aprendizaje automático?

La figura 13 muestra la cantidad de artículos según área clínica, las áreas más vistas son Oncología, Cardiología y Neurología.

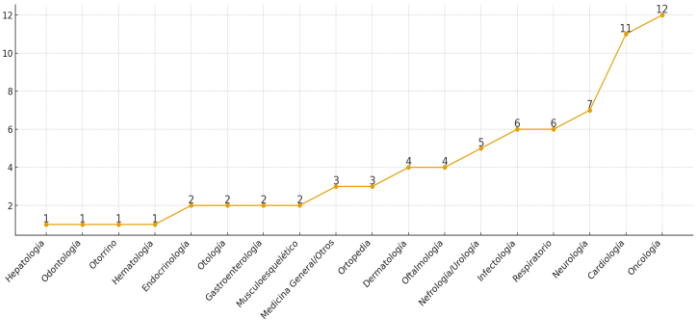


Figura 13. Artículos según área clínica.

La tabla 4 muestra la clasificación de los artículos según área clínica.

Área clínica	Frecuencia	#de articulo
Cardiología	11	1, 14, 24, 27, 29, 32, 35, 41, 46, 55, 69
Dermatología	4	12, 52, 61, 72
Endocrinología	2	65, 71
Gastroenterología	2	21, 42
Hematología	1	49
Hepatología	1	57
Infectología	6	4, 9, 51, 56, 62, 64
Medicina General/Otros	3	15, 25, 31
Musculoesquelético	2	10, 38
Nefrología/Urología	5	16, 36, 58, 63, 73
Neurología	7	23, 33, 37, 39, 40, 43, 68
Odontología	1	45
Oftalmología	4	13, 17, 22, 28
Oncología	12	3, 7, 19, 20, 30, 34, 47, 48, 54, 66, 67, 70
Ortopedia	3	18, 53, 60
Otología	2	6, 8
Otorrino	1	11
Respiratorio	6	2, 5, 26, 44, 50, 59

Tabla 14. Clasificación de artículos según área clínica.

4. RQ4 ¿Qué tipo de datos son los más empleados en la aplicación de aprendizaje automático a la detección de enfermedades caninas?

La figura 14 muestra la cantidad de artículos según tipo de dato y área clínica, se evidencia que el tipo de dato mas usado son las imágenes.

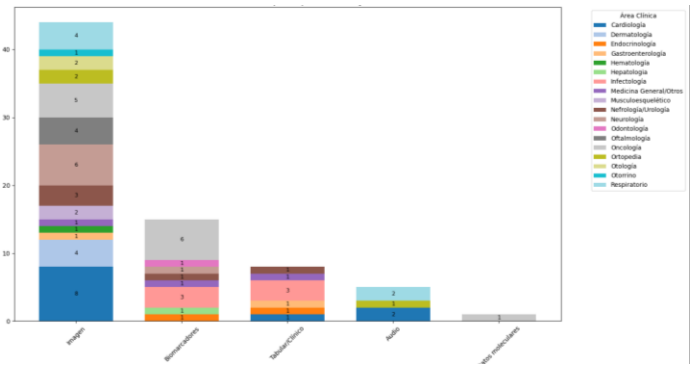


Figura 14. Artículos según tipo de dato y área clínica.

La tabla 5 muestra la clasificación de artículos según tipo de dato

Tipo de dato	Frecuencia	# de articulo
Imagen	43	2, 3, 6, 8, 10, 11, 12, 13, 14, 16, 17, 18, 20, 21, 22, 23, 24, 26, 28, 29, 31, 32, 33, 36, 37, 38, 39, 41, 43, 46, 48, 49, 50, 52, 53, 54, 55, 58, 59, 61, 67, 68, 69, 72
Biomarcadores	16	4, 7, 9, 15, 19, 30, 40, 45, 47, 51, 57, 63, 65, 66, 70
Tabular/Clínico	8	25, 35, 42, 56, 62, 64, 71, 73
Audio	5	1, 5, 27, 44, 60
Datos moleculares	1	34

Tabla 5. Clasificación de artículos según tipo de dato.

5. RQ5 ¿Qué tipo de tareas son las más empleadas en los modelos de Aprendizaje Automático para la detección de enfermedades caninas?

La figura 15 muestra la distribución de artículos según tipo de tarea. Se ve claramente que los tipos de tareas mas usadas son la detección binaria y clasificación multiclase.

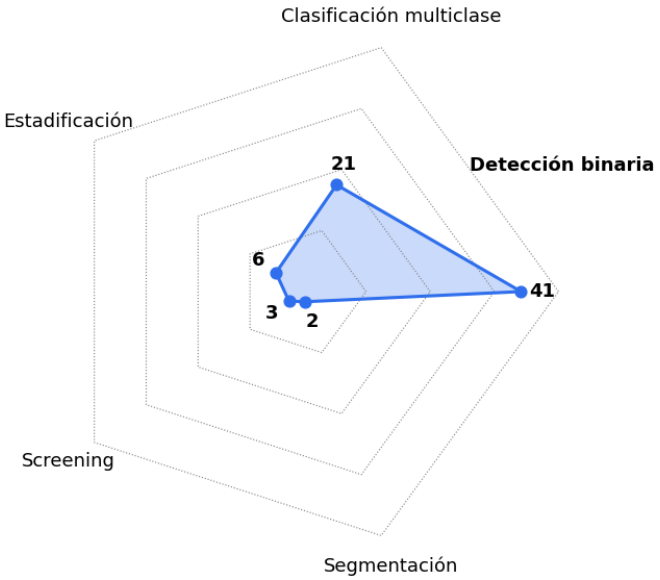


Figura 15. Distribución de artículos según tipo de tarea.

La tabla 6 muestra la Clasificación de artículos según tipo de tarea.

Tipo de tarea	Frecuencia	# de articulo
Detección binaria	41	3, 4, 5, 6, 9, 10, 12, 14, 18, 19, 21, 23, 30, 32, 34, 37, 38, 39, 41, 42, 43, 44, 45, 47, 50, 51, 53, 55, 56, 59, 60, 63, 64, 65, 66, 67, 68, 69, 70, 71, 73
Clasificación multiclase	21	7, 8, 11, 13, 17, 20, 22, 24, 25, 28, 29, 31, 35, 36, 48, 49, 52, 54, 57, 61, 72
Estadificación	6	1, 2, 26, 27, 33, 46
Screening	3	15, 40, 62
Segmentación	2	16, 58

Tabla 6. Clasificación de artículos según tipo de tarea

V. CONCLUSIONES

Esta revisión sistemática demuestra que el Aprendizaje Automático se ha consolidado como una herramienta clave en el diagnóstico temprano de enfermedades caninas. El análisis de 94 estudios revela tendencias claras en producción científica, modelos utilizados y aplicaciones clínicas.

En primer lugar, Estados Unidos, Corea del Sur y Reino Unido lideran la producción científica reciente, concentrando tanto la mayor cantidad como la mayor calidad de investigaciones. Esto evidencia que el avance del ML veterinario se encuentra fuertemente impulsado por países con infraestructura tecnológica especializada.

En cuanto a los modelos, las CNN y U-Net son, por amplio margen, las arquitecturas más empleadas, especialmente en tareas basadas en imagen. Les siguen los algoritmos de ML clásico, utilizados principalmente en biomarcadores y datos tabulares. Se observa además un crecimiento emergente de transformers, señal de una futura transición hacia modelos multimodales.

Respecto a las áreas clínicas, las más abordadas son Oncología, Cardiología y Neurología, reflejando tanto su relevancia epidemiológica como la disponibilidad de datos complejos que favorecen el uso del ML. Asimismo, el tipo de dato predominante son las imágenes médicas, mientras que los biomarcadores y datos clínicos complementan el panorama con aplicaciones cada vez más variadas.

Finalmente, las tareas más comunes son la detección binaria y la clasificación multiclase, fundamentales para decisiones clínicas automatizadas. Aunque en menor medida, tareas como la estadificación y la segmentación muestran un crecimiento importante.

En conjunto, los resultados indican que el ML no solo mejora la precisión diagnóstica, sino que también amplía el acceso a evaluaciones objetivas, rápidas y reproducibles. Su creciente adopción sugiere que en los próximos años será un componente esencial en la medicina veterinaria, impulsando diagnósticos más tempranos y un manejo clínico más eficiente.

VI. Referencias

[1] Lee, SY., Lee, S., Kim, SH. *et al.* Deep learning-based evaluation of the severity of mitral regurgitation in canine myxomatous mitral valve disease patients using digital stethoscope recordings. *BMC Vet Res* **21**, 326 (2025). https://doi.org/10.1186/s12917-025-04802-z

[2] da Silva Andrade, G., Hirokawa Higa, G.T., da Silva Ribeiro, J.F. *et al.* Bulldogs stenosis degree classification using synthetic images created by generative artificial intelligence. *Sci Rep* **15**, 9800 (2025). https://doi.org/10.1038/s41598-025-92769-0

[3] Ahmed, I., Zhang, W., Cheung, P., Basnet, V., Ali, Z., Tse, M. P., Hill, F., Chan, T. T. L., Hu, H., Li, X., & Lau, C. (2025). AI-based virtual immunocytochemistry for rapid and robust fine needle aspiration biopsy diagnosis. *Diagnostic pathology*, *20*(1), 86. https://doi.org/10.1186/s13000-025-01687-2

[4] Volpe, J., Costa, F. S., Sachuk, B., Camilo, I., Faria, A., de Andrade, H. M., Silva, S. M., & Souto, D. (2025). Interpretating SPR-Derived Reaction Kinetics via Self-Organizing Maps for Diagnostic Applications. *ACS sensors*, *10*(10), 8129–8139. https://doi.org/10.1021/acssensors.5c03250

[5] Kwon, DY., Oh, YJ. & Kim, H. Dog Cough Sound Classification Using Neural Networks for Diagnosing Bronchial Diseases. *J. Electr. Eng. Technol.* **20**, 4387–4395 (2025). https://doi.org/10.1007/s42835-025-02306-2

[6] Zhao, Z., Mac Aodha, O., Daniel, C., Israeliantz Gunz, N., Orekhova, A., Schwarz, T., Mellanby, R., & Banks, C. (2025). Deep learning can be used to classify the disease status of the canine middle ear from computed tomographic images. *Veterinary Radiology & Ultrasound*, *66*(5), 1-8. Article e70065. https://doi.org/10.1111/vru.70065

[7] Brown, J. R., Shen, L., Fulton, N., Johnston, S. A., & Sykes, K. F. (2025). High-sensitivity multicancer detection of stage 1 cancer in dogs. *American journal of veterinary research*, *86*(9), ajvr.25.02.0068. https://doi.org/10.2460/ajvr.25.02.0068

[8] Apostolopoulos, N., Murray, S., Aravamuthan, S., & Döpfer, D. (2025). Detection of canine external ear canal lesions using artificial intelligence. *Veterinary dermatology*, *36*(4), 424–432. https://doi.org/10.1111/vde.13332

[9] Mihailescu, M. I., Simion, V. E., Ursachi, A., Somaudon, V., Jaimes-Mogollón, A. L., Acevedo, C. M. D., Cuastumal, C., Lixandru, L. M., Llauradó, X., Bari, N. E., Bouchikhi, B., Laouini, D., Diouani, M. F., Bessou, A. B. E., Messaoudi, N., Zeroual, F., & Marascu, V. (2025). A Non-Invasive Diagnostic Platform for Canine Leishmaniasis Using VOC Analysis and Distributed Veterinary Infrastructure. *Veterinary sciences*, *12*(8), 732. https://doi.org/10.3390/vetsci12080732

[10] Agrawal, K. K., & Kumar, G. (2025). *LiDSCUNet++: A lightweight depth separable convolutional UNet++ for vertebral column segmentation and spondylosis detection*. Research in Veterinary Science, 192, 105703. https://doi.org/10.1016/j.rvsc.2025.105703

[11] Istrate, A., Constantinescu, R., Anandavel, L., Rajeshkumar Tandel, S., Dye, S., & Dye, C. (2025). A Novel Machine Learning Model for the Automated Diagnosis of Nasal Pathology in Canine Patients. *Animals*, *15*(12), 1718. https://doi.org/10.3390/ani15121718

[12] Ok, C. H. (2025). *Sequential convolutional neural network techniques to improve detection of lesions in dogs*. Indian Journal of Animal Research, 59(6), 926–933. https://doi.org/10.18805/IJAR.BF-1821

[13] Park, S., Go, S., Kim, S., & Shim, J. (2025). Deep Learning-Based Classification of Canine Cataracts from Ocular B-Mode Ultrasound Images. *Animals*, *15*(9), 1327. https://doi.org/10.3390/ani15091327

[14] Lopes, L. A., Diniz, A. das N., & Silva Neto, H. (2025). Detection of left atrial enlargement in dogs using deep learning on thoracic radiographs. *Veterinary Medicine*, 19(1), 31–37. https://doi.org/10.26605/medvet-v19n1-6639

[15] Omura, K., Ide, K., Takahashi, M., Furusawa, Y., Kobayashi, M., Miyagawa, Y., Fujiwara-Igarashi, A., Teshima, T., Kubo, Y., Yasuda, A., Yoshida, K., Hayakawa, N., Kobayashi, M., & Momoi, Y. (2024). Development of a sensitive disease-screening model using comprehensive circulating microRNA profiles in dogs: A pilot study. *Veterinary and animal science*, *27*, 100414. https://doi.org/10.1016/j.vas.2024.100414

[16] Choi, J., Hwang, G., Ji, Y., Yoon, H., & Lee, S. J. (2025). PFSH-Net: Parallel frequency-spatial hybrid network for segmentation of kidney stones in pre-contrast computed tomography images of dogs. *Computers in biology and medicine*, *186*, 109609. https://doi.org/10.1016/j.compbiomed.2024.109609

[17] Jones, A., & Vijayan, T. (2024). *AI-driven canine cataract detection: A machine learning approach using support vector machine*. Journal of the Chinese Institute of Engineers, 48, 1–9. https://doi.org/10.1080/02533839.2024.2420100

[18] Hauback, M. N., Huynh, B. N., Steiro, S. E. D., Groendahl, A. R., Bredal, W., Tomic, O., Futsaether, C. M., & Skogmo, H. K. (2025). Deep learning can detect elbow disease in dogs screened for elbow dysplasia. *Veterinary radiology & ultrasound : the official journal of the American College of Veterinary Radiology and the International Veterinary Radiology Association*, *66*(1), e13465. https://doi.org/10.1111/vru.13465

[19] Sharif, H., Arabi Belaghi, R., Jagarlamudi, K. K., Saellström, S., Wang, L., Rönnberg, H., & Eriksson, S. (2025). A novel cross-validated machine learning based Alertix-Cancer Risk Index for early detection of canine malignancies. *Frontiers in veterinary science*, *12*, 1570106. https://doi.org/10.3389/fvets.2025.1570106

[20] Abbate, J. M., Mangraviti, D., Brunetti, B., Cafarella, C., Rigano, F., Iaria, C., Marino, F., & Mondello, L. (2025). Machine learning approach in canine mammary tumour classification using rapid evaporative ionization mass spectrometry. *Analytical and bioanalytical chemistry*, *417*(2), 373–388. https://doi.org/10.1007/s00216-024-05656-4

[21] Kanski, S., Busch, K., Hailmann, R., & Weber, K. (2025). Performance of the Vetscan Imagyst in point-of-care detection of *Giardia duodenalis* in canine fecal samples. *Journal of veterinary diagnostic investigation : official publication of the American Association of Veterinary Laboratory Diagnosticians, Inc*, *37*(1), 63–70. https://doi.org/10.1177/10406387241279177

[22] Burić, M., & Ivašić-Kos, M. (2025). *Next-generation computer vision in veterinary medicine: A study on canine ophthalmology*. IEEE Transactions on Artificial Intelligence, 6(7), 1884–1893. https://doi.org/10.1109/TAI.2025.3530380

[23] Huang, S., Deng, G., Kang, Y. *et al.* Exploring deep learning strategies for intervertebral disc herniation detection on veterinary MRI. *Sci Rep* 14, 16705 (2024). https://doi.org/10.1038/s41598-024-67749-5

[24] Li, J., Zhang, Y. Regressive vision transformer for dog cardiomegaly assessment. *Sci Rep* **14**, 1539 (2024). https://doi.org/10.1038/s41598-023-50063-x

[25] Kim, K. B., Song, D. H., & Park, H. J. (2024). Developing a Robust Fuzzy Inference Algorithm in a Dog Disease Pre-Diagnosis System for Casual Owners. *Animals : an open access journal from MDPI*, *14*(24), 3561. https://doi.org/10.3390/ani14243561

[26] Suksangvoravong, H., Choisunirachon, N., Tongloy, T., Chuwongin, S., Boonsang, S., Kittichai, V., & Thanaboonnipat, C. (2024). Automatic classification and grading of canine tracheal collapse on thoracic radiographs by using deep learning. *Veterinary radiology & ultrasound : the official journal of the American College of Veterinary Radiology and the International Veterinary Radiology Association*, *65*(6), 679–688. https://doi.org/10.1111/vru.13413

[27] McDonald, A., Novo Matos, J., Silva, J., Partington, C., Lo, E. J. Y., Luis Fuentes, V., Barron, L., Watson, P., & Agarwal, A. (2024). A machine-learning algorithm to grade heart murmurs and stage preclinical myxomatous mitral valve disease in dogs. *Journal of veterinary internal medicine*, *38*(6), 2994–3004. https://doi.org/10.1111/jvim.17224

[28] Buric, M., Grozdanic, S., & Ivasic-Kos, M. (2024). Diagnosis of ophthalmologic diseases in canines based on images using neural networks for image segmentation. *Heliyon*, *10*(19), e38287. https://doi.org/10.1016/j.heliyon.2024.e38287

[29] Valente, C., Wodzinski, M., Guglielmini, C., Poser, H., Chiavegato, D., Zotti, A., Venturini, R., & Banzato, T. (2024). Development of an artificial intelligence-based algorithm for predicting the severity of myxomatous mitral valve disease from thoracic radiographs by using two grading systems. *Research in veterinary science*, *178*, 105377. https://doi.org/10.1016/j.rvsc.2024.105377

[30] Enginler, S.Ö., Küçükdeniz, T., Dal, G.E. *et al.* Enhancing electrochemical detection through machine learning-driven prediction for canine mammary tumor biomarker with green silver nanoparticles. *Anal Bioanal Chem* **416**, 5071–5088 (2024). https://doi.org/10.1007/s00216-024-05444-0

[31] Taranum, A., Metan, J., Yogegowda, P., & Krishnappa, C. (2024). *Canine disease prediction using multi-directional intensity proportional pattern with correlated textural neural network*. The International Arab Journal of Information Technology, 21(5). https://doi.org/10.34028/iajit/21/5/11

[32] Youssef, K., Zhang, X., Yoosefian, G., Chen, Y., Chan, S. F., Yang, H. J., Vora, K., Howarth, A., Kumar, A., Sharif, B., & Dharmakumar, R. (2024). Enabling Reliable Visual Detection of Chronic Myocardial

Infarction with Native T1 Cardiac MRI Using Data-Driven Native Contrast Mapping. *Radiology. Cardiothoracic imaging*, *6*(4), e230338. https://doi.org/10.1148/ryct.230338

[33] Niemeyer, F., Galbusera, F., Beukers, M., Jonas, R., Tao, Y., Fusellier, M., Tryfonidou, M. A., Neidlinger-Wilke, C., Kienle, A., & Wilke, H. J. (2024). Automatic grading of intervertebral disc degeneration in lumbar dog spines. *JOR spine*, *7*(2), e1326. https://doi.org/10.1002/jsp2.1326

[34] Flory, A., Ruiz-Perez, C. A., Clavere-Graciette, A. G., Rafalko, J. M., O'Kell, A. L., Flesner, B. K., McLennan, L. M., Hicks, S. C., Nakashe, P., Phelps-Dunn, A., DiMarzio, L. R., Warren, C. D., Cohen, T. A., Chibuk, J., Chorny, I., Grosu, D. S., Tsui, D. W. Y., Tynan, J. A., & Kruglyak, K. M. (2024). Clinical validation of a blood-based liquid biopsy test integrating cell-free DNA quantification and next-generation sequencing for cancer screening in dogs. *Journal of the American Veterinary Medical Association*, *262*(5), 665–673. https://doi.org/10.2460/javma.23.10.0564

[35] Engel-Manchado, J., Montoya-Alonso, J. A., Doménech, L., Monge-Utrilla, O., Reina-Doreste, Y., Matos, J. I., Caro-Vadillo, A., García-Guasch, L., & Redondo, J. I. (2024). Machine Learning Techniques for Canine Myxomatous Mitral Valve Disease Classification: Integrating Anamnesis, Quality of Life Survey, and Physical Examination. *Veterinary sciences*, *11*(3), 118. https://doi.org/10.3390/vetsci11030118

[36] Yu, H., Lee, I. G., Oh, J. Y., Kim, J., Jeong, J. H., & Eom, K. (2024). Deep learning-based ultrasonographic classification of canine chronic kidney disease. *Frontiers in veterinary science*, *11*, 1443234. https://doi.org/10.3389/fvets.2024.1443234

[37] Park, J., Cho, H., Ji, Y., Lee, K., & Yoon, H. (2024). Detection of spondylosis deformans in thoracolumbar and lumbar lateral X-ray images of dogs using a deep learning network. *Frontiers in veterinary science*, *11*, 1334438. https://doi.org/10.3389/fvets.2024.1334438

[38] Chaouki, B., Logovi, M., Djemai, S., & Lassakeur, I. E. (2023). *Computer-aided diagnosis of canine hip dysplasia using a deep learning approach in a novel X-ray image dataset*. Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization, 11, 1–11. https://doi.org/10.1080/21681163.2023.2274947

[39] Park, J., Cho, H., Ji, Y., Lee, K., & Yoon, H. (2024). Development of a deep learning model for automatic detection of narrowed intervertebral disc space sites in caudal thoracic and lumbar lateral X-ray images of dogs. *Frontiers in veterinary science*, *11*, 1453765. https://doi.org/10.3389/fvets.2024.1453765

[40] Kim, C. Y., Kim, J., Yoon, S., Yi, I. J., Lee, H., Seo, S., Kim, D. W., Ko, S., Kim, S. A., Kwon, C., & Yi, S. S. (2024). Advancing the early detection of canine cognitive dysfunction syndrome with machine learning-enhanced blood-based biomarkers. *Frontiers in veterinary science*, *11*, 1390296. https://doi.org/10.3389/fvets.2024.1390296

[41] Jaworski, L. T. B. N., Restani, G. M., Oliveira, L. F. D., & Froes, T. R. (2024). *Evaluation of the effectiveness of two neural networks (ResNet50V2 and Inception V3) in identifying left atrial enlargement in adult dogs*. **Archives of Veterinary Science, 29**(3). https://doi.org/10.5380/avs.v29i3.95142

[42] Farhoodimoghadam, M., Reagan, K. L., & Zwingenberger, A. L. (2024). Diagnosis and classification of portosystemic shunts: a machine learning retrospective case-control study. *Frontiers in veterinary science*, *11*, 1291318. https://doi.org/10.3389/fvets.2024.1291318

[43] Cumber, J., Scales-Theobald, E., Rusbridge, C., & Wells, K. (2025). A data driven approach for soft tissue biomarker identification linked to Chiari-like malformation and syringomyelia. *Frontiers in veterinary science*, *11*, 1492259. https://doi.org/10.3389/fvets.2024.1492259

[44] Oren, A., Türkcü, J. D., Meller, S., Lazebnik, T., Wiegel, P., Mach, R., Volk, H. A., & Zamansky, A. (2023). BrachySound: machine learning based assessment of respiratory sounds in dogs. *Scientific reports*, *13*(1), 20300. https://doi.org/10.1038/s41598-023-47308-0

[45] Ruparell, A., Gibbs, M., Colyer, A., Wallis, C., Harris, S., & Holcombe, L. J. (2023). Developing diagnostic tools for canine periodontitis: combining molecular techniques and machine learning models. *BMC veterinary research*, *19*(1), 163. https://doi.org/10.1186/s12917-023-03668-3

[46] Solomon, J., Bender, S., Durgempudi, P., Robar, C., Cocchiaro, M., Turner, S., Watson, C., Healy, J., Spake, A., & Szlosek, D. (2023). Diagnostic validation of vertebral heart score machine learning algorithm for canine lateral chest radiographs. *The Journal of small animal practice*, *64*(12), 769–775. https://doi.org/10.1111/jsap.13666

[47] Nam, A. R., Heo, M., Lee, K. H., Kim, J. Y., Won, S. H., & Cho, J. Y. (2023). The landscape of PBMC methylome in canine mammary tumors reveals the epigenetic regulation of immune marker genes and its potential application in predicting tumor malignancy. *BMC genomics*, *24*(1), 403. https://doi.org/10.1186/s12864-023-09471-6

[48] Fragoso-Garcia, M., Wilm, F., Bertram, C. A., Merz, S., Schmidt, A., Donovan, T., Fuchs-Baumgartinger, A., Bartel, A., Marzahl, C., Diehl, L., Puget, C., Maier, A., Aubreville, M., Breininger, K., & Klopfleisch, R. (2023). Automated diagnosis of 7 canine skin tumors using machine learning on H&E-stained whole slide images. *Veterinary pathology*, *60*(6), 865–875. https://doi.org/10.1177/03009858231189205

[49] Pasupa, K., Vatathanavaro, S. & Tungjitnob, S. Convolutional neural networks based focal loss for class imbalance problem: a case study of canine red blood cells morphology classification. *J Ambient Intell Human Comput* **14**, 15259–15275 (2023). https://doi.org/10.1007/s12652-020-01773-x

[50] Pomerantz, L. K., Solano, M., & Kalosa-Kenyon, E. (2023). Performance of a commercially available artificial intelligence software for the detection of confirmed pulmonary nodules and masses in canine thoracic radiography. *Veterinary Radiology & Ultrasound, 64*(6), 881–889. https://doi.org/10.1111/vru.13287

[51] Coelho, M. L., França, T., Fontoura Mateus, N. L., da Costa Lima Junior, M. S., Cena, C., & do Nascimento Ramos, C. A. (2023). Canine visceral leishmaniasis diagnosis by UV spectroscopy of blood serum and machine learning algorithms. *Photodiagnosis and photodynamic therapy*, *42*, 103575. https://doi.org/10.1016/j.pdpdt.2023.103575

[52] Upadhyay, A., Singh, G., Mhatre, S. *et al.* Dog Skin Diseases Detection and Identification Using Convolutional Neural Networks. *SN COMPUT. SCI.* **4**, 250 (2023). https://doi.org/10.1007/s42979-022-01645-5

[53] Shim H, Lee J, Choi S, et al. Deep learning-based diagnosis of stifle joint diseases in dogs. *Vet Radiol Ultrasound*. 2023; 64: 113–122. https://doi.org/10.1111/vru.13181

[54] Hubbard-Perez, M., Luchian, A., Milford, C., & Ressel, L. (2024). Use of deep learning for the classification of hyperplastic lymph node and common subtypes of canine lymphomas: a preliminary study. *Frontiers in veterinary science*, *10*, 1309877. https://doi.org/10.3389/fvets.2023.1309877

[55] Jeong, Y., & Sung, J. (2022). An automated deep learning method and novel cardiac index to detect canine cardiomegaly from simple radiography. *Scientific reports*, *12*(1), 14494. https://doi.org/10.1038/s41598-022-18822-4

[56] Pijnacker, T., Bartels, R., van Leeuwen, M. *et al.* Identification of parameters and formulation of a statistical and machine learning model to identify *Babesia canis* infections in dogs using available ADVIA hematology analyzer data. *Parasites Vectors* **15**, 41 (2022). https://doi.org/10.1186/s13071-022-05163-4

[57] Imbery, C.A., Dieterle, F., Ottka, C. *et al.* Metabolomic serum abnormalities in dogs with hepatopathies. *Sci Rep* **12**, 5329 (2022). https://doi.org/10.1038/s41598-022-09056-5

[58] Ji, Y., Cho, H., Seon, S., Lee, K., & Yoon, H. (2022). A deep learning model for CT-based kidney volume determination in dogs and normal reference definition. *Frontiers in veterinary science*, *9*, 1011804. https://doi.org/10.3389/fvets.2022.1011804

[59] Müller, T. R., Solano, M., & Tsunemi, M. H. (2022). Accuracy of artificial intelligence software for the detection of confirmed pleural effusion in thoracic radiographs in dogs. *Veterinary radiology & ultrasound : the official journal of the American College of Veterinary Radiology and the International Veterinary Radiology Association*, *63*(5), 573–579. https://doi.org/10.1111/vru.13089

[60] Figueirinhas, P., Sanchez, A., Rodríguez, O., Vilar, J. M., Rodríguez-Altónaga, J., Gonzalo-Orden, J. M., & Quesada, A. (2022). Development of an Artificial Neural Network for the Detection of Supporting Hindlimb Lameness: A Pilot Study in Working Dogs. *Animals*, *12*(14), 1755. https://doi.org/10.3390/ani12141755

[61] Hwang, S., Shin, H.K., Park, J.M. *et al.* Classification of dog skin diseases using deep learning with images captured from multispectral imaging device. *Mol. Cell. Toxicol.* 18, 299–309 (2022). https://doi.org/10.1007/s13273-022-00249-7

[62] Reagan, K. L., Deng, S., Sheng, J., Sebastian, J., Wang, Z., Huebner, S. N., Wenke, L. A., Michalak, S. R., Strohmer, T., & Sykes, J. E. (2022). *Use of machine-learning algorithms to aid in the early detection of leptospirosis in dogs*. Journal of Veterinary Diagnostic Investigation, 34(4), 612–621. https://doi.org/10.1177/10406387221096781

[63] Gal A, Fries R, Kadotani S, et al. Canine urinary lactate and cortisol metabolites in hypercortisolism, nonadrenal disease, congestive heart failure, and health. *J Vet Diagn Invest*. 2022;34(4):622-630. doi:10.1177/10406387221099916

[64] Ferreira, T. S., Santana, E. E. C., Jacob Junior, A. F. L., Silva Junior, P. F., Bastos, L. S., Silva, A. L. A., Melo, S. A., Cruz, C. A. M., Aquino, V.

S., Castro, L. S. O., Lima, G. O., & Freire, R. C. S. (2022). Diagnostic Classification of Cases of Canine Leishmaniasis Using Machine Learning. *Sensors (Basel, Switzerland)*, *22*(9), 3128. https://doi.org/10.3390/s22093128

[65] Imbery, C. A., Dieterle, F., Ottka, C., Weber, C., Schlotterbeck, G., Müller, E., Lohi, H., & Giger, U. (2022). Metabolomic Abnormalities in Serum from Untreated and Treated Dogs with Hyper- and Hypoadrenocorticism. *Metabolites*, *12*(4), 339. https://doi.org/10.3390/metabo12040339

[66] Makielski, K.M., Donnelly, A.J., Khammanivong, A. *et al.* Development of an exosomal gene signature to detect residual disease in dogs with osteosarcoma using a novel xenograft platform and machine learning. *Lab Invest* **101**, 1585–1596 (2021). https://doi.org/10.1038/s41374-021-00655-w

[67] Ye, Y., Sun, W. W., Xu, R. X., Selmic, L. E., & Sun, M. (2021). Intraoperative assessment of canine soft tissue sarcoma by deep learning enhanced optical coherence tomography. *Veterinary and comparative oncology*, *19*(4), 624–631. https://doi.org/10.1111/vco.12747

[68] Biercher, A., Meller, S., Wendt, J., Caspari, N., Schmidt-Mosig, J., De Decker, S., & Volk, H. A. (2021). Using Deep Learning to Detect Spinal Cord Diseases on Thoracolumbar Magnetic Resonance Images of Dogs. *Frontiers in veterinary science*, *8*, 721167. https://doi.org/10.3389/fvets.2021.721167

[69] Zhang, M., Zhang, K., Yu, D., Xie, Q., Liu, B., Chen, D., Xv, D., Li, Z., & Liu, C. (2021). Computerized assisted evaluation system for canine cardiomegaly via key points detection with deep learning. *Preventive veterinary medicine*, *193*, 105399. https://doi.org/10.1016/j.prevetmed.2021.105399

[70] Nuojin Cheng, Ashley J Schulte, Fadil Santosa, Jong Hyuk Kim, Machine learning application identifies novel gene signatures from transcriptomic data of spontaneous canine hemangiosarcoma, *Briefings in Bioinformatics*, Volume 22, Issue 4, July 2021, bbaa252, https://doi.org/10.1093/bib/bbaa252

[71] Schofield, I., Brodbelt, D. C., Kennedy, N., Niessen, S. J. M., Church, D. B., Geddes, R. F., & O'Neill, D. G. (2021). Machine-learning based prediction of Cushing's syndrome in dogs attending UK primary-care veterinary practice. *Scientific reports*, *11*(1), 9035. https://doi.org/10.1038/s41598-021-88440-z

[72] Smith, A., Carroll, P. W., Aravamuthan, S., Walleser, E., Lin, H., Anklam, K., Döpfer, D., & Apostolopoulos, N. (2023). *Computer vision model for the detection of canine pododermatitis and neoplasia of the paw*. **Veterinary Dermatology,** **35**(2), 138–147. https://doi.org/10.1111/vde.13221

[73] Kokkinos, Y., Morrison, J., Bradley, R. *et al.* An early prediction model for canine chronic kidney disease based on routine clinical laboratory tests. *Sci Rep* **12**, 14489 (2022). https://doi.org/10.1038/s41598-022-18793-6

[74] Lancho Barrantes, B. S. (2025). Academic perspectives on bibliometrics in a leading UK research university. *Education for Information*, *41*(2), 88-106. https://doi.org/10.1177/01678329251323443 (Original work published 2025)